

Conformer-vMF 自己研究：評価基準一覧と先行研究比較

白黒基調・LaTeX 版（ただし、先行研究より数値上高い参考比較のみ赤字）

重要な注記：本資料の比較は、入力条件・データセット・評価指標が完全に一致する「公式順位比較」ではない。特に MIREX は主に音声入力・共通テストセット、本研究は MIDI 入力・独自評価である。赤字は「表中で比較した代表値より数値上高い」ことを示すに留め、統計的優位性や MIREX 順位上位を意味しない。

1 評価基準一覧：初学者向け解説と本研究の最新版結果

分類	評価項目	初学者向けの説明	本研究の結果	この結果から言えること
データ規模	学習 MIDI 数	AI に学習させた MIDI 曲数。データが多いほど一般化しやすいが、自己研究では処理可能性も重要。	300 曲	小規模ながら、MIDI から vMF 特徴量を作成し、学習まで行える実験基盤を構築できた。
データ規模	変換済みデータ数	MIDI を AI が扱えるテンソル形式に変換したファイル数。	1788 個	MIDI から学習用データへの変換処理が安定して実行できた。
入力表現	group_dim	1 つの音楽状態を表す特徴量の次元数。	82 次元	音高、五度圏、拍節、和声方向などをまとめた表現を構築できた。
和声認識	root Accuracy	コードの中心音（C, C#, D など）をどれだけ当てられたか。	0.7979	AI 自身の予測条件でも、root を約 80% で推定できた。
和声認識	root Macro-F1	12 種類の root を偏りなく当てられているかを見る指標。	0.8025	多い root だけでなく、全体として比較的安定した root 推定ができている。
和声認識	chord-like Accuracy	その時刻の音集合が「和音らしいか」を当てる正解率。各音がコード構成音かどうかではない。	0.9416	和音的な時刻と非和音的な時刻を高精度に分けられた。
和声認識	chord-like Macro-F1	和音的・非和音的な時刻をバランスよく判定できているか。	0.8556	片方のクラスだけに偏らず、和音らしさを安定して判定できている。
和声認識	cs_template Accuracy	AI が予測した root を使って、コード型・和声テンプレートを当てる精度。	0.8939	生成時に近い条件でも、コード型を約 89% で分類できた。
和声認識	cs_template Macro-F1	出現頻度の少ない template も含めて、バランスよく分類できたか。	0.6354	頻出 template には強い一方、少数 template には改善余地がある。
和声認識	seventh type Macro-F1	7th 系コードの細かい種類をバランスよく分類できたか。	0.9168	7th 系の細かな和声分類は非常に高精度である。
拍節文脈	onset Accuracy	音が鳴る位置・区切りをどれくらい当てられたか。	0.7534	拍・発音位置の情報もある程度学習できている。
生成	n_events	生成された音符イベント数。	100	16 小節生成として一定数の音符を生成できた。
生成	unique_pitch	生成中に使われた音高の種類数。	21	音高の多様性のある程度保てている。
生成	repeat_rate	同じ音を繰り返す割合。高すぎるとメロディが張り付きやすい。	0.46	同音反復は残るが、改良前より改善傾向がある。
生成	step_rate	隣接音へなめらかに動く割合。	0.26	なめらかな旋律運動が増えた。
生成	skip_rate	少し離れた音へ動く割合。	0.17	中程度の跳躍は維持されている。

分類	評価項目	初学者向けの説明	本研究の結果	この結果から言えること
生成	leap_rate	大きく跳ぶ割合。高すぎると不自然になりやすい。	0.10	大跳躍が抑えられ、旋律が安定した。
生成	same_direction_rate	上行または下行に進み続ける割合。高すぎると単調になりやすい。	0.47	一方向への偏りがやや抑えられている。

2 評価基準の補足解説

用語	初学者向け説明
Accuracy	全体の正解率。100 問中何問当たったかを見る。データの偏りが強いと、多い種類だけ当てても高く見える場合がある。
Macro-F1	各クラスを同じ重みで見たバランス指標。major のように多いコードだけでなく、dim や sus など少ないコードも見たいときに重要。
teacher-root 条件	正解の root をモデルに与えた理想条件。コード型分類の上限性能を見やすい。
predicted-root 条件	AI 自身が予測した root を使う実運用に近い条件。本研究の最新版まとめではこちらを重視する。
chord-like	「その時刻の音集合が和音的か」を見る二値判定。単音メロディだけの時刻は non-chord-like になりやすい。
cs_template	root を基準にしたコード型・和声テンプレート。コード名そのものより、構成音パターンの分類に近い。
repeat/step/skip/leap	生成されたメロディの動き方を調べる指標。repeat は同音反復、step はなめらかな進行、leap は大跳躍を表す。

3 先行研究・ベンチマークとの評価比較

評価領域	先行研究・基準	先行研究側の代表値・評価内容	本研究の対応結果	比較判定	注意点
root 推定	MIREX 2025 Audio Chord Estimation	Billboard2013 等の音声コード推定。上位手法の MirexRoot は概ね 80% 前後。	root Accuracy 79.79%	近い水準	MIREX は音声入力・共通データ、本研究は MIDI 入力・独自評価。直接順位比較ではない。
root 推定	BACHI / Harmony Transformer v2	POP909-CL 上で Root: BACHI 89.6%, Harmony Transformer v2 90.5%。	root Accuracy 79.79%	未到達	symbolic chord recognition 上位研究に対しては root 推定に改善余地がある。
コード型分類	BACHI	POP909-CL 上で Quality 86.8%, Full Chord 82.3%。	cs_template Accuracy 89.39%	数値上は上回る参考値あり	指標が完全一致しない。cs_template は本研究内の template 分類であり、BACHI の Full Chord と同一ではない。
コード型のバランス	BACHI	Quality や Full Chord を含む包括的な symbolic chord recognition。	cs_template Macro-F1 63.54%	改善余地あり	Accuracy は高いが、Macro-F1 は少数クラスへの弱さを示す。

評価領域	先行研究・基準	先行研究側の代表値・評価内容	本研究の対応結果	比較判定	注意点
7th 系分類	MIREX 2025 Audio Chord Estimation	Billboard2013 の Sevenths 評価で上位手法は概ね 64–66% 程度。	seventh type Macro-F1 91.68%	数値上は高い	本研究は MIDI 入力, none 除外, 5 クラス条件であり, MIREX Sevenths と条件が異なる。
和音的時刻判定	Boundary-aware chord recognition / BACHI	BACHI は chord boundary detection を導入し, root・quality・bass 推定に利用。	chord-like Acc 94.16%, Macro-F1 85.56%	強いが直接比較不可	公開値と同一指標ではないため赤字比較は行わない。
拍節・発音位置	MIREX ACE / Beat Tracking 系	MIREX ACE では chord onset / duration も対象。Beat Tracking は拍位置推定。	onset Accuracy 75.34%	関連あり	本研究は MIDI 上の onset 分類であり, 音声から拍位置を推定する Beat Tracking とは異なる。
16 小節生成	MIREX 2025 Symbolic Music Generation	4 小節 prompt から 12 小節を続け, 16 小節ピアノ曲を生成。主観評価は coherency, creativity, structuredness, musicality。	16 小節生成, n_events 100	設定が近い	MIREX は主観評価, 本研究は客観的な旋律運動指標。今後, 主観評価を追加すると比較しやすい。
生成客観指標	MusPy	n_pitches_used, pitch_range, pitch entropy, empty-beat rate, groove consistency 等を提供。	unique_pitch 21, step 0.26, leap 0.10	客観指標化可能	unique_pitch は n_pitches_used に近い。repeat/step/leap は本研究独自の旋律運動指標。
演奏表情生成	VirtuosoNet / ScorePerformer / RenCon	tempo, dynamics, articulation, timing, bar/beat/onset style など扱う表情付きピアノ演奏生成。	velocity 式, timing residual, vMF 方向一致度 $A_{t,i} = e_{t,i}^\top \mu_t$	発展可能性あり	現時点では表情生成の主観評価・聴取実験が不足している。

4 赤字にした数値の扱い

- **cs_template Accuracy 89.39%** は, BACHI の Quality 86.8% や Full Chord 82.3% より数値上は高い。ただし, 評価ラベル・データセット・指標が一致しないため, 参考比較である。
- **seventh type Macro-F1 91.68%** は, MIREX 2025 Audio Chord Estimation の Sevenths 評価の上位値より数値上高い。ただし, 本研究は MIDI 入力・none 除外・5 クラス条件であり, 音声入力の MIREX とは直接比較できない。
- 以上より, 赤字は「本研究が公式に先行研究を上回った」という意味ではなく, 「研究資料上, 強調できる可能性がある数値」を示す。

5 まとめ文

本研究の最新版では, MIDI 演奏を vMF 超球面表現へ変換し, Conformer で時系列文脈を学習することにより, root 推定, chord-like 判定, コード template 分類, seventh 分類, および 16 小節程度の生成までを統合的に扱った。和声認識では, root Accuracy 79.79%, chord-like Accuracy 94.16%, cs_template Accuracy 89.39%, seventh type Macro-F1 91.68% を示した。生成では, unique_pitch 21, step_rate 0.26, leap_rate 0.10 となり, 大跳躍を抑えつつ音高の多様性を保つ生成が確認された。先行研究との比較では, MIREX や BACHI と同一条件ではないため直接順位比較はできないが, 評価軸としては MIREX Audio Chord Estimation, BACHI, MIREX Symbolic Music Generation, MusPy, VirtuosoNet/ScorePerformer/RenCon と接続可能である。

6 参考情報

項目	参照元
MIREX 2025 Audio Chord Estimation	https://music-ir.org/mirex/wiki/2025%3AAudio_Chord_Estimation
MIREX 2025 Audio Chord Estimation Results	https://music-ir.org/mirex/wiki/2025%3AAudio_Chord_Estimation_Results
BACHI: Boundary-Aware Symbolic Chord Recognition	https://arxiv.org/abs/2510.06528
MIREX 2025 Symbolic Music Generation	https://music-ir.org/mirex/wiki/2025%3ASymbolic_Music_Generation
MusPy Metrics	https://hermandong.com/muspy/metrics.html
VirtuosoNet	https://archives.ismir.net/ismir2019/paper/000112.pdf
ScorePerformer	https://archives.ismir.net/ismir2023/paper/000069.pdf